

Задача обучения линейного классификатора

Обучающая выборка: $X^\ell = (x_i, y_i)_{i=1}^\ell$, $x_i \in \mathbb{R}^n$, $y_i \in \{-1, +1\}$

- Линейная модель классификации:

$$a(x, w) = \text{sign}\langle x, w \rangle$$


- Непрерывная аппроксимация бинарной функции потерь:

$$Q(w) = \sum_{i=1}^{\ell} [a(x_i, w)y_i < 0] \leq \sum_{i=1}^{\ell} \mathcal{L}(\langle x_i, w \rangle y_i) \rightarrow \min_w$$

Отступ (margin) объекта x_i : $M_i(w) = \langle x_i, w \rangle y_i$

- Логарифмическая функция потерь, как функция отступа M :

$$\mathcal{L}(M) = \log(1 + e^{-M})$$



Обоснование логарифмической функции потерь

$(x_i, y_i)_{i=1}^{\ell} \sim p(x, y; w)$ — выборка независимых наблюдений.

Принцип максимума правдоподобия:

$$L(w) = \log \prod_{i=1}^{\ell} p(x_i, y_i; w) = \sum_{i=1}^{\ell} \log P(y_i|x_i; w)p(x_i) \rightarrow \max_w .$$

Вероятностная модель порождения данных с параметром w :

- $p(x)$ не зависит от параметра модели w ,
- $P(y|x; w)$ описывается линейной моделью классификации:

$$P(y_i|x_i; w) = \frac{1}{1 + \exp(-\langle x_i, w \rangle y_i)} = \sigma(\langle x_i, w \rangle y_i),$$

где $\sigma(M) = \frac{1}{1+e^{-M}}$ — сигмоидная функция.

Тогда задачи $Q(w) \rightarrow \min$ и $L(w) \rightarrow \max$ эквивалентны:

$$Q(w) = \sum_{i=1}^{\ell} \log(1 + \exp(-\langle w, x_i \rangle y_i)) \rightarrow \min_w .$$

- Метод первого порядка — стохастический градиент:

$$w^{(t+1)} := w^{(t)} + \eta_t y_i x_i (1 - \sigma_i),$$

η_t — градиентный шаг,

$\sigma_i = \sigma(\langle x_i, w \rangle y_i) = P(y_i|x_i)$ — вероятность правильной классификации x_i .

- Метод второго порядка (Ньютона-Рафсона) приводит к IRLS, Iteratively Reweighted Least Squares:

$$w^{(t+1)} := w^{(t)} + \eta_t (F^\top \Lambda F)^{-1} F^\top \tilde{y},$$

F — матрица объекты–признаки $\ell \times n$,

$\tilde{y} = (y_i(1 - \sigma_i))$ — модифицированный вектор ответов,
 $\Lambda = \text{diag}((1 - \sigma_i)/\sigma_i)$ — диагональная матрица.

Пример. Бинаризация признаков и скоринговая карта

Задача кредитного scoringа:

- x_i — заемщики
- $y_i \in \{-1(\text{bad}), +1(\text{good})\}$

Бинаризация признаков $f_j(x)$:

$$b_{jk}(x) = [f_j(x) \in D_{jk}]$$

Возраст	до 25	5
	25 - 40	10
	40 - 50	15
	50 и больше	10
Собственность	владелец	20
	совладелец	15
	съемщик	10
	другое	5
Работа	руководитель	15
	менеджер среднего звена	10
	служащий	5
	другое	0
Стаж	1/безработный	0
	1..3	5
	3..10	10
	10 и больше	15
Работа_мужа /жены	нет/домохозяйка	0
	руководитель	10
	менеджер среднего звена	5
	служащий	1

Оценка риска (математического ожидания) потерь объекта x :

$$R(x) = \sum_{y \in Y} D_{xy} P(y|x) = \sum_{y \in Y} D_{xy} \sigma(\langle w, x \rangle y),$$

где D_{xy} — величина потери для (x, y) .

Методика VaR (Value at Risk)

Оценка функции распределения потерь:

- для каждого x_i разыгрывается N раз исход $y_i \sim P(y|x_i)$;
- строится эмпирическое распределение потерь $V = \sum_{i=1}^{\ell} D_{x_i y_i}$;
- 99%-квантиль эмпирического распределения определяет величину резервируемого капитала

- L_2 -регуляризация решает проблему мультиколлинеарности (сокращает веса линейно зависимых признаков):

$$Q(w) = \sum_{i=1}^{\ell} \log(1 + \exp(-\langle w, x_i \rangle y_i)) + \tau \sum_{j=1}^n w_j^2 \rightarrow \min_w .$$

- L_1 -регуляризация имеет эффект отбора признаков (обнуляет веса w_j неинформативных признаков):

$$Q(w) = \sum_{i=1}^{\ell} \log(1 + \exp(-\langle w, x_i \rangle y_i)) + \tau \sum_{j=1}^n |w_j| \rightarrow \min_w .$$

- Используется также их комбинация — ElasticNet.

Коэффициент регуляризации τ подбирается по скользящему контролю.

- Логистическая регрессия — это линейный классификатор,
- оценивающий апостериорные вероятности классов $P(y|x)$, необходимые в прикладных задачах оценивания рисков.
- Регуляризация улучшает обобщающую способность логистической регрессии:
 - L_2 -регуляризация — при мультиколлинеарности признаков;
 - L_1 -регуляризация — для отбора признаков;
 - ElasticNet — для менее агрессивного отбора признаков.