

Многомерная линейная регрессия

$f_1(x), \dots, f_n(x)$ — числовые признаки;

Модель многомерной линейной регрессии:

$$f(x, \alpha) = \sum_{j=1}^n \alpha_j f_j(x), \quad \alpha \in \mathbb{R}^n.$$

Матричные обозначения:

$$\underset{\ell \times n}{F} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}, \quad \underset{\ell \times 1}{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_\ell \end{pmatrix}, \quad \underset{n \times 1}{\alpha} = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{pmatrix}.$$

Функционал квадрата ошибки:

$$Q(\alpha, X^\ell) = \sum_{i=1}^{\ell} (f(x_i, \alpha) - y_i)^2 = \|F\alpha - y\|^2 \rightarrow \min_{\alpha}.$$

Нормальная система уравнений

Необходимое условие минимума в матричном виде:

$$\frac{\partial Q}{\partial \alpha}(\alpha) = 2F^T(F\alpha - y) = 0,$$

откуда следует *нормальная система задачи МНК*:

$$F^T F \alpha = F^T y,$$

где $F^T F$ — $n \times n$ -матрица.

Решение системы: $\alpha^* = (F^T F)^{-1} F^T y = F^+ y$.

Значение функционала: $Q(\alpha^*) = \|P_F y - y\|^2$,

где $P_F = FF^+ = F(F^T F)^{-1} F^T$ — проекционная матрица.

Произвольная $\ell \times n$ -матрица представима в виде сингулярного разложения (singular value decomposition, SVD):

$$F = VDU^T.$$

Основные свойства сингулярного разложения:

- 1 $\ell \times n$ -матрица $V = (v_1, \dots, v_n)$ ортогональна, $V^T V = I_n$, столбцы v_j — собственные векторы матрицы FF^T ;
- 2 $n \times n$ -матрица $U = (u_1, \dots, u_n)$ ортогональна, $U^T U = I_n$, столбцы u_j — собственные векторы матрицы $F^T F$;
- 3 $n \times n$ -матрица D диагональна, $D = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$, $\lambda_j \geq 0$ — собственные значения матриц $F^T F$ и FF^T , $\sqrt{\lambda_j}$ — сингулярные числа матрицы F .

Псевдообратная F^+ , вектор МНК-решения α^* ,
МНК-аппроксимация целевого вектора $F\alpha^*$:

$$F^+ = (UDV^\top VDU^\top)^{-1} UDV^\top = UD^{-1}V^\top = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j v_j^\top;$$

$$\alpha^* = F^+ y = UD^{-1}V^\top y = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j (v_j^\top y);$$

$$F\alpha^* = P_F y = (VDU^\top)UD^{-1}V^\top y = VV^\top y = \sum_{j=1}^n v_j (v_j^\top y);$$

$$\|\alpha^*\|^2 = \|D^{-1}V^\top y\|^2 = \sum_{j=1}^n \frac{1}{\lambda_j} (v_j^\top y)^2.$$

Проблема: мультиколлинеарность при $\lambda_j \rightarrow 0$.

Если имеются сингулярные числа, близкие к нулю, то:

- матрица $\Sigma = F^T F$ плохо обусловлена;
- решение становится неустойчивым и неинтерпретируемым, слишком большие коэффициенты $\|\alpha_j^*\|$ разных знаков;
- возникает переобучение:
 - на обучении $Q(\alpha^*, X^\ell) = \|F\alpha^* - y\|^2$ мало;
 - на контроле $Q(\alpha^*, X^k) = \|F'\alpha^* - y'\|^2$ велико;

Стратегии устранения мультиколлинеарности и переобучения:

- отбор признаков: $f_1, \dots, f_n \rightarrow f_{j_1}, \dots, f_{j_m}$, $m \ll n$.
- регуляризация: $\|\alpha\| \rightarrow \min$;
- преобразование признаков: $f_1, \dots, f_n \rightarrow g_1, \dots, g_m$, $m \ll n$;

- Задача многомерной линейной регрессии может быть решена через сингулярное разложение
- Мультиколлинеарность приводит к плохой обусловленности, неустойчивости и переобучению
- Методы устранения мультиколлинеарности (гребневая регрессия, метод главных компонент) также связаны с сингулярным разложением (об этом в следующих лекциях)

Регуляризация (гребневая регрессия)

Штраф за увеличение нормы вектора весов $\|\alpha\|$:

$$Q_\tau(\alpha) = \|F\alpha - y\|^2 + \frac{\tau}{2}\|\alpha\|^2,$$

где τ — неотрицательный параметр регуляризации.

Модифицированное МНК-решение (τI_n — «гребень»):

$$\alpha_\tau^* = (F^\top F + \tau I_n)^{-1} F^\top y.$$

Преимущество сингулярного разложения:

можно подбирать параметр τ , вычислив SVD только один раз.

Регуляризованный МНК через сингулярное разложение

Вектор регуляризованного МНК-решения α_τ^*
и МНК-аппроксимация целевого вектора $F\alpha_\tau^*$:

$$\alpha_\tau^* = U(D^2 + \tau I_n)^{-1} D V^\top y = \sum_{j=1}^n \frac{\sqrt{\lambda_j}}{\lambda_j + \tau} u_j(v_j^\top y);$$

$$F\alpha_\tau^* = V D U^\top \alpha_\tau^* = V \operatorname{diag}\left(\frac{\lambda_j}{\lambda_j + \tau}\right) V^\top y = \sum_{j=1}^n \frac{\lambda_j}{\lambda_j + \tau} v_j(v_j^\top y);$$

$$\|\alpha_\tau^*\|^2 = \|(D^2 + \tau I_n)^{-1} D V^\top y\|^2 = \sum_{j=1}^n \frac{\lambda_j}{(\lambda_j + \tau)^2} (v_j^\top y)^2.$$

$F\alpha_\tau^* \neq F\alpha^*$, но зато решение становится гораздо устойчивее.

Выбор параметра регуляризации τ

Контрольная выборка: $X^k = (x'_i, y'_i)_{i=1}^k$;

$$F'_{k \times n} = \begin{pmatrix} f_1(x'_1) & \dots & f_n(x'_1) \\ \dots & \dots & \dots \\ f_1(x'_k) & \dots & f_n(x'_k) \end{pmatrix}, \quad y'_{k \times 1} = \begin{pmatrix} y'_1 \\ \dots \\ y'_k \end{pmatrix}.$$

Вычисление функционала Q на контрольных данных T раз потребует $O(kn^2 + knT)$ операций:

$$Q(\tau) = \|F'\alpha_\tau^* - y'\|^2 = \left\| \underbrace{F'U}_{k \times n} \operatorname{diag}\left(\frac{\sqrt{\lambda_j}}{\lambda_j + \tau}\right) \underbrace{V^\tau y}_{n \times 1} - y' \right\|^2.$$

Зависимость $Q(\tau)$ обычно имеет характерный минимум.

Регуляризация сокращает «эффективную размерность»

Сжатие (shrinkage) или сокращение весов (weight decay):

$$\|\alpha_\tau^*\|^2 = \sum_{j=1}^n \frac{\lambda_j}{(\lambda_j + \tau)^2} (v_j^\top y)^2 < \|\alpha^*\|^2 = \sum_{j=1}^n \frac{1}{\lambda_j} (v_j^\top y)^2.$$

Почему говорят о *сокращении эффективной размерности*?

Роль размерности играет след проекционной матрицы:

$$\text{tr } F(F^\top F)^{-1} F^\top = \text{tr}(F^\top F)^{-1} F^\top F = \text{tr } I_n = n.$$

При использовании регуляризации:

$$\text{tr } F(F^\top F + \tau I_n)^{-1} F^\top = \text{tr} \text{diag} \left(\frac{\lambda_j}{\lambda_j + \tau} \right) = \sum_{j=1}^n \frac{\lambda_j}{\lambda_j + \tau} < n.$$

LASSO — Least Absolute Shrinkage and Selection Operator,
два эквивалентных варианта постановки задачи:

$$Q(\alpha) = \|F\alpha - y\|^2 \rightarrow \min_{\alpha} \text{ при } \sum_{j=1}^n |\alpha_j| \leq \kappa;$$

$$Q(\alpha) = \|F\alpha - y\|^2 + \tau \sum_{j=1}^n |\alpha_j| \rightarrow \min_{\alpha};$$

После замены переменных

$$\begin{cases} \alpha_j = \alpha_j^+ - \alpha_j^-; & \alpha_j^+ \geq 0; \quad \alpha_j^- \geq 0. \\ |\alpha_j| = \alpha_j^+ + \alpha_j^-; \end{cases}$$

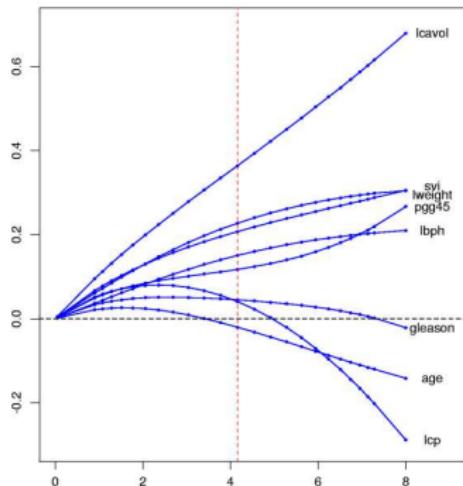
ограничения принимают канонический вид:

$$\sum_{j=1}^n \alpha_j^+ + \alpha_j^- \leq \kappa; \quad \alpha_j^+ \geq 0; \quad \alpha_j^- \geq 0.$$

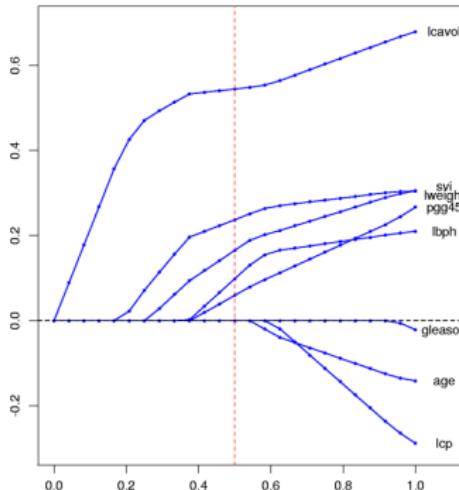
Чем меньше κ , тем больше j таких, что $\alpha_j^+ = \alpha_j^- = 0$.

Сравнение гребневой регрессии и Лассо

Зависимость $\{\alpha_j\}$ от $\frac{1}{\tau}$



Зависимость $\{\alpha_j\}$ от κ



Задача диагностики рака (prostate cancer, UCI)

T.Hastie, R.Tibshirani, J.Friedman. The Elements of Statistical Learning.
Springer, 2001.

- Гребневая регрессия удобно вводится и интерпретируется через сингулярное разложение
- Гребневая регрессия сокращает веса признаков
- LASSO обнуляет веса признаков
- Оба метода имеют параметр регуляризации (селективности), позволяющий определять число признаков (сложность модели) по внешним критериям (по кросс-валидации).

$f_1(x), \dots, f_n(x)$ — исходные числовые признаки;
 $g_1(x), \dots, g_m(x)$ — новые числовые признаки, $m \leq n$;

Требование: старые признаки должны линейно восстанавливаться по новым:

$$\hat{f}_j(x) = \sum_{s=1}^m g_s(x) u_{js}, \quad j = 1, \dots, n, \quad \forall x \in X,$$

как можно точнее на обучающей выборке x_1, \dots, x_ℓ :

$$\sum_{i=1}^{\ell} \sum_{j=1}^n (\hat{f}_j(x_i) - f_j(x_i))^2 \rightarrow \min_{\{g_s(x_i)\}, \{u_{js}\}}$$

Матрицы «объекты–признаки», старая и новая:

$$F_{\ell \times n} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \dots & \dots & \dots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}; \quad G_{\ell \times m} = \begin{pmatrix} g_1(x_1) & \dots & g_m(x_1) \\ \dots & \dots & \dots \\ g_1(x_\ell) & \dots & g_m(x_\ell) \end{pmatrix}.$$

Матрица линейного преобразования новых признаков в старые:

$$U_{n \times m} = \begin{pmatrix} u_{11} & \dots & u_{1m} \\ \dots & \dots & \dots \\ u_{n1} & \dots & u_{nm} \end{pmatrix}; \quad \hat{F} = GU^\top \xrightarrow{\text{хотим}} F.$$

Найти: и новые признаки G , и преобразование U :

$$\sum_{i=1}^{\ell} \sum_{j=1}^n (\hat{f}_j(x_i) - f_j(x_i))^2 = \|GU^\top - F\|^2 \rightarrow \min_{G, U}$$

Теорема

Если $m \leq \text{rk } F$, то минимум $\|GU^\top - F\|^2$ достигается, когда столбцы U — это с.в. матрицы $F^\top F$, соответствующие m максимальным с.з. $\lambda_1, \dots, \lambda_m$, а матрица $G = FU$.

При этом:

- ① матрица U ортонормирована: $U^\top U = I_m$;
- ② матрица G ортогональна: $G^\top G = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$;
- ③ $U\Lambda = F^\top FU$; $G\Lambda = FF^\top G$;
- ④ $\|GU^\top - F\|^2 = \|F\|^2 - \text{tr } \Lambda = \sum_{j=m+1}^n \lambda_j$.

Если взять $m = n$, то:

❶ $\|GU^\top - F\|^2 = 0;$

- ❷ представление $\hat{F} = GU^\top = F$ точное и совпадает с сингулярным разложением при $G = V\sqrt{\Lambda}$:

$$F = GU^\top = V\sqrt{\Lambda}U^\top; \quad U^\top U = I_m; \quad V^\top V = I_m.$$

- ❸ линейное преобразование U работает в обе стороны:

$$F = GU^\top; \quad G = FU.$$

Поскольку новые признаки некоррелированы ($G^\top G = \Lambda$), преобразование U называется *декоррелирующим* (или преобразованием Карунена–Лоэва).

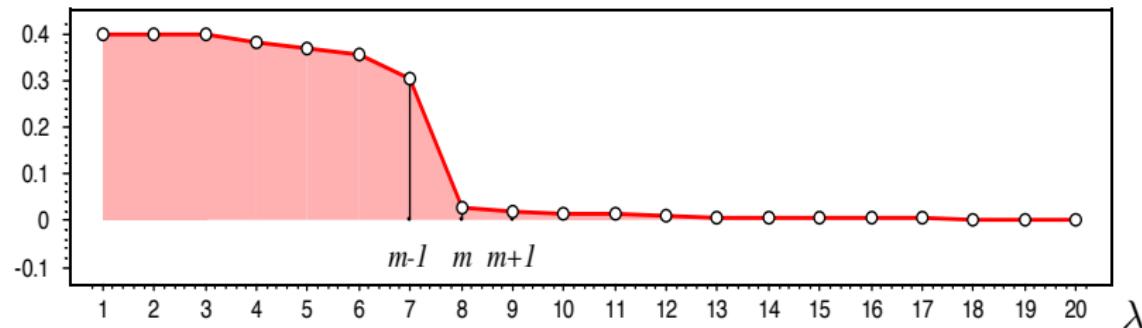
Эффективная размерность выборки

Упорядочим с.з. $F^T F$ по убыванию: $\lambda_1 \geq \dots \geq \lambda_n \geq 0$.

Эффективная размерность выборки — это наименьшее целое m , при котором

$$E_m = \frac{\|GU^T - F\|^2}{\|F\|^2} = \frac{\lambda_{m+1} + \dots + \lambda_n}{\lambda_1 + \dots + \lambda_n} \leq \varepsilon.$$

Критерий «крутого склона»: находим m : $E_{m-1} \gg E_m$:



Решение задачи НК для МЛР в новых признаках

Задача наименьших квадратов для МЛР: $\|F\alpha - y\|^2 \rightarrow \min_{\alpha}$.

Заменим F на её приближение $\underbrace{G}_{\ell \cdot m} \cdot \underbrace{U^T}_{m \cdot n}$, предполагая $m \leq n$:

$$\|G \underbrace{U^T \alpha}_{\beta} - y\|^2 = \|G\beta - y\|^2 \rightarrow \min_{\beta}.$$

Связь нового и старого вектора коэффициентов:

$$\beta = U^T \alpha; \quad \alpha = U\beta.$$

Решение задачи наименьших квадратов относительно β (единственное отличие — m слагаемых вместо n):

$$\beta^* = D^{-1} V^T y; \quad \alpha^* = UD^{-1}V^T y = \sum_{j=1}^m \frac{1}{\sqrt{\lambda_j}} u_j(v_j^T y);$$

$$G\beta^* = VV^T y = \sum_{j=1}^m v_j(v_j^T y);$$

- Метод главных компонент позволяет приближать матрицу её низкоранговым разложением.
- Для этого достаточно взять из SVD-разложения первые m сингулярных чисел и векторов матрицы.
- Этот приём широко используется в анализе данных — в задачах регрессии, классификации, сжатия данных, обработки изображений.