

Федеральное государственное бюджетное образовательное учреждение высшего образования

#### «МИРЭА – Российский технологический университет» РТУ МИРЭА

#### ЛЕКЦИОННЫЕ МАТЕРИАЛЫ

Технологии хранения в системах кибербезопасности (наименование дисциплины (модуля) в соответствии с учебным планом) Уровень бакалавриат (бакалавриат, магистратура, специалитет) Форма обучения очная (очная, очно-заочная, заочная) Направление(-я) 10.05.04 Информационно-аналитические системы безопасности подготовки (код(-ы) и наименование(-я)) Институт Кибербезопасности и цифровых технологий (ИКБ) (полное и краткое наименование) Кафедра КБ-2 «Прикладные информационные технологии» (полное и краткое наименование кафедры, реализующей дисциплину (модуль)) Лектор к.т.н., Селин Андрей Александрович (сокращенно – ученая степень, ученое звание; полностью – ФИО) Используются в данной редакции с учебного года 2024/2025 (учебный год цифрами) Проверено и согласовано « » 2024 г. А.А. Бакаев (подпись директора Института/Филиала

с расшифровкой)



# Технологии хранения в системах кибербезопасности



# Учебные вопросы лекции:

- TES
- 2. Типы поиска в ES

### Введение

ElasticSearch — NoSQL БД/поисковая система с открытым исходным кодом, предназначенная для полнотекстового поиска. Она позволяет хранить, анализировать и получать большие объемы данных в режиме реального времени.

Для анализа и поиска ElasticSearch использует библиотеку Apache Lucene. Написана она на языке Java и доступна для многих платформ. Все неструктурированные данные хранятся в формате JSON. Для работы с данными у Elastic Search есть специальное REST API.

elasticsearch

# Основные задачи, решаемые ElasticSearch:

- полнотекстовый поиск;
- поиск по параметрам;
- Агрегация данных для статистики и их последующая визуализация;
- Генерация вариантов для автозаполнения.

#### Эквивалентные термины в Elasticsearch.

```
Например тип для лекций:

{
    "articleid": 1,
    "name": "Elasticsearch"
}

Тип для учебных вопросов:
{
    "commentid": "WetKRvTNWfhuxCa_lTcb",
    "articleid": 1,
    "topic": "ES"
}
```

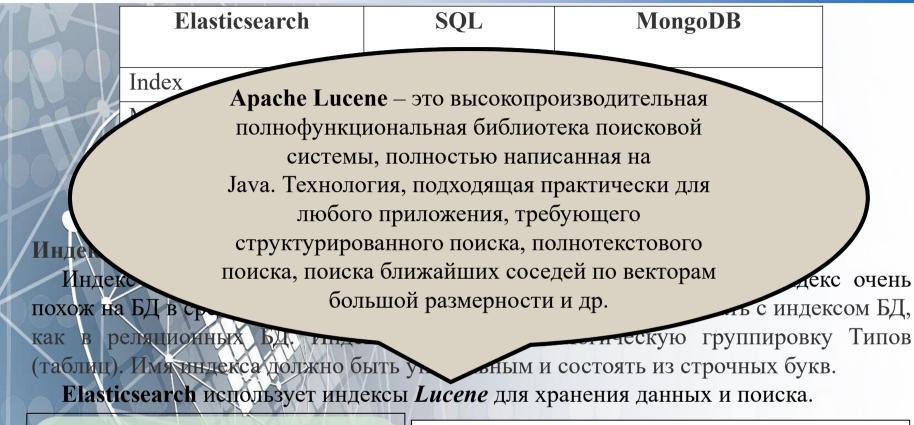
При желании можно определить отношения между различными типами. Например, отношение между родителями и дочерними элементами может быть определено между лекциями и комментариями. Лекция (родитель) может иметь один или несколько учебных вопросов (детей).

```
Elasticsearch поддерживает
Кроме
        ΤΟΓΟ
хранение вложенных объектов:
 "id": 2,
 "name": "Мария",
 "age": 20,
 "gender": "Ж",
 "email": "enkova@mirea.ru",
 "address": {
    "street": "Проспект Вернадского",
    "city": "Москва",
    "state": "Россия",
    "zip": 98765
```

```
"id": 1,
  "name": "Василий",
  "age": 21,
  "gender": "M",
  "email": "zaicev@mirea.ru"
},

{
  "id": 2,
  "name": "Мария",
  "age": 20,
  "gender": "Ж",
  "email": "enkova@mirea.ru"
}
```

id	name	age	gender	email
1	Василий	21	M	zaicev@mirea.ru
2	Мария	20	Ж	enkova@mirea.ru



Shard 1 Shard 2

Shard n-1 Shard n

**Shard** в **Elasticsearch** — это логическая единица хранения данных на уровне базы, которая является отдельным экземпляром Lucene.

один или оолее шардов, их совокупность и является хранилищем.

Для того, чтобы обращаться к распределенной системе шардов, нам необходимо иметь некий координирующий узел, именно он будет принимать запросы и давать задания на запись или получение данных. То есть помимо хранения данных мы выделяем еще один вариант поведения программы – координирование.

Узел. Узловая машина является частью сервера и называется отдельной машиной. Она хранит данные и предоставляет возможности индексации и поиска, а также другие узлы кластера. Благодаря концепции горизонтального масштабирования возможно виртуально добавить бесконечное количество узлов в кластер ES, чтобы дать ему гораздо больше возможностей и, в том числе, возможностей индексирования.

Есть два вида узлов — CRUD-узлы и координирующие узлы. Назовем их data node и coordinating node. Несколько машин, объединенных в сеть напоминают кластер.

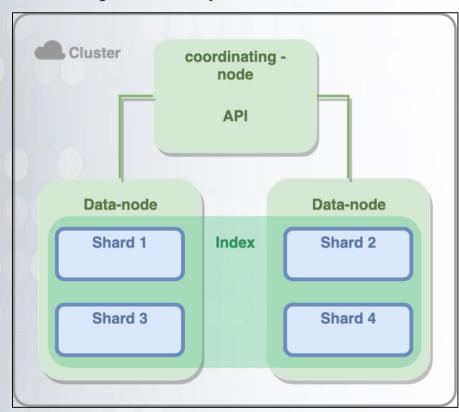
Кластер – это набор серверных машин (узлов), на которых хранятся данные. Данные разделены между несколькими узлами, чтобы их можно было реплицировать, и единственная точка отказа (SPoF) не возникла с ES-сервером. Имя кластера по умолчанию: Elasticsearch. Каждый узел в кластере подключается к кластеру с помощью URL-адреса и имени кластера, поэтому важно, чтобы это имя

было четким и понятным.

Каждый запущенный экземпляр Elasticsearch является отдельным узлом (node). Cluster — это совокупность определенных нод. Когда вы запускаете один экземпляр ваш кластер будет состоять из одной ноды.

Для того чтобы объединить узлы в кластер они должны соответствовать ряду требований:

- Ноды должны иметь одинаковую версию.
- Имя кластера cluster.name в конфигурации должно быть одинаковым.



Очевидно, что data-ноды будут часто обращаться к диску и использовать значительные объемы памяти в процессе работы. Не все данные будут запрашиваться одинаково часто. Данные постепенно "остывают" по мере снижения запросов (жизненный цикл хранения данных). Популярные публикации нужно хранить там, откуда их можно быстро достать, а забытые «анекдоты 90-х» можно положить подальше.

Начиная с версии 6.7 Elasticsearch предлагает механизм управления жизненным циклом. Для этого доступны три типа нод:

- hot,
- →warm,
- cold.

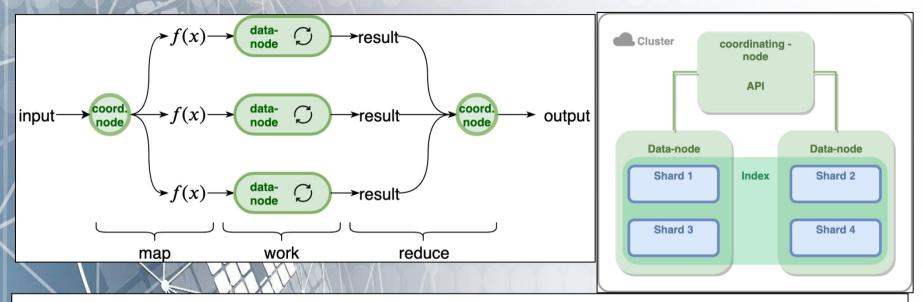
Существует рекомендация по выбору аппаратных конфигураций для каждого из типов. Например hot-ноды должны иметь быстрые SSD, для warm и cold достаточно HDD-диска. Оптимальные соотношения память/диск будут следующими:

hot — 1:30

warm — 1:100

cold - 1:500

Важнейшим аспектом в использовании распределенных систем является параллельное выполнение задач.



Именно такой механизм помогает выполнять операции с шардами.

Координирующий узел получит запрос, предварительно переформулирует его для внутрикластерного взаимодействия и выполнит запросы к worker-нодам(в данном случае к data-нодам).

Следовательно, **coordinating-ноды** должны иметь достаточный ресурс памяти, ЦП и быструю сеть, но при этом могут иметь скромный диск, ведь не осуществляют хранения данных.

#### Управление кластером

Предположим возможность **coordinating-нодам** управления состоянием кластера. Один узел примет решение о перемещении шарда на одну **data-ноду**, а второй о перемещении того же на другую. Список возможных общекластерных действий может быть довольно широким, а список возможных конфликтов еще шире.

Такие важные решения должен принимать один центральный узел. Для каждого типа действий необходимо выделять отдельную роль, чтобы избежать потерь производительности на ноде. И "главный в кластере" звучит как отдельная ответственность. Такие ноды нзываются master-node. Активный мастер всегда должен быть один, он будет управлять топологией кластера: создавать новый индекс, выделять и распределять шарды, перемещать их и объединять в случае необходимости. Мастер всегда знает все о состоянии кластера.

В кластере **Elasticsearch** обязательно должен быть как минимум один узел, отвечающий требованиям master node. Для этого в конфигурации ноды необходимо установить значение

#### node.master: true.

**Маster-ноды** отвечают за важные, но довольно легкие общекластерные действия. Это означает, что они требуют большого ресурса и высокой стабильности от физической ноды. В кластерах от 10 нод необходимо всегда выделять отдельные **only-master узлы**.

#### Репликация данных

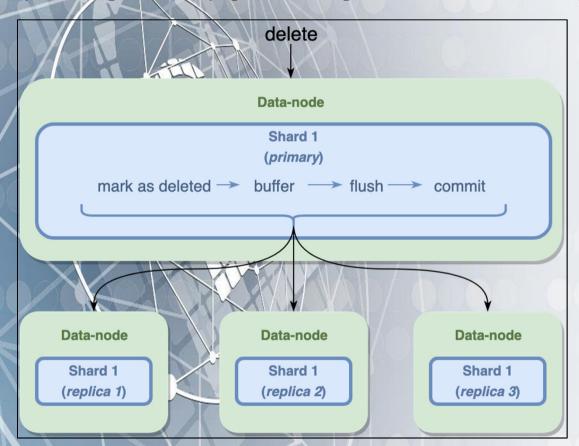
```
Чтобы жестко установить количество реплик индекса используется параметр number_of_replicas. Так же мы можем изменить это значение в рантайме выполнив запрос:

PUT / _settings {
    "index": {
        "number_of_replicas": someVal
     }
```

о эти уэлы должны хранить только шарды ренлик.



С учетом реплик запись данных будет происходить в два этапа, в первом запись затронет только первичный шард и только после того, как произойдет операция **flush** слияния изменений и операция **commit** фиксации в индексе Lucene, будет отправлен внутренний запрос на изменение всех реплик.



Для мониторинга состояния кластера в Elasticsearch существует cluster health status. Статус может иметь три значения:

green – все хорошо;

yellow – есть утраченные шарды, кластер полностью работоспособен, но работает на репликах;

red – есть утраченные шарды, кластер неработоспособен или часть данных недоступна.

Для максимальной стабильности кластера необходимо, чтобы количество дата-нод было больше или равно количества реплик.

#### Отказоустойчивость

Теперь данные будут доступны даже в случае сбоя одного из хранящих узлов. Но что будет если кластер потеряет мастера? Потеря единственного мастера равноценна потере кластера. Вариант выхода – поднять несколько мастеров.

Если есть, например, два управляющих узла, как понять, какой из них в данный момент должен управлять кластером? Как они смогут договориться о своих решениях?

В каждый момент времени должен быть только один управляющий кластером узел. То есть при потере мастера его место должен занять один из кандидатов.

В Elasticsearch настройка node.master: true не будет означать, что данный узел является мастером, это всего лишь скажет о том, что он может быть выбран в качестве главного узла. По умолчанию настройки будут установлены следующим образом:

- node.master: true
- node.data: true

**Пример.** Главный управляющий узел стал недоступен для кластера, кластер берет первого кандидата и устанавливает его на вакантное место. Спустя определенное время первый мастер возвращается в кластер и ничего не знает о том, что его место уже занято. Мастер-ноды являются своего рода его *мозгом*, и теперь мозг кластера становится разделен. Это классическая проблема распределенных систем и она так и называется *split-brain problem*.



Как только кнастер теряет управляющий узел, должен быть запущен процесс голосования. Важно определить какой из кандидатов больше всего подходит на роль главного узла. Такой кандидат должен обладать самой актуальной информацией о кластере.

Сравнив номера версий мы можем определить наиболее подходящих кандидатов на роль мастера. Теперь если отпавшая мастер-нода вернется в кластер, то процесс голосования запустится снова и будет выбран единственный управляющий узел.

Теперь важно понять когда можно считать, что голосование прошло успешно? Если проголосовали все участники? Или половина? Или другое любое другое количество? Решение этой проблемы заключается в определении *кворума*.

Это умное название для контрольного количества голосующих. Очевидно, что такое важное решение как выбор мастера должно приниматься на основе большинства, то есть 50%+один голос. Справедливо, надежно. Это значение и станет кворумом.

Таким образом, количество кандидатов на мастера должно быть нечетным и не меньше трех. Рекомендуется использовать простую формулу для расчета оптимально количества таких нод:

# КОЛИЧЕСТВО\_КАНДИДАТОВ = ОБЩЕЕ\_КОЛИЧЕСТВО\_НОД/2 + 1

Решения для любых общекластерных действий принимаются путем голосования, и вей необходимая для голосования информация содержится в конфигурации голосования. Право голоса определяет еще одну роль, ведь право голоса не означает, что узел может быть кандидатом.

B Elasticsearch узлы, которые могут участвовать в голосовании можно определить в конфигурации: node.voting\_only: true.

#### Транспорт

Пришло время поговорить о том, как общаться с кластером из внешних систем, и как будут общаться узлы внутри кластера. Есть ряд плюсов и минусов использования и *традиционных*, и специальных протоколов. Для краткого сравнения существует таблица.

Протокол	Достоинства	Недостатки
HTTP	Низкий порог вхождения, в сравнении с нативным протоколом. Для	Клиент не знает топологию кластера, поэтому может потребовать большее количество запросов для получения
ES Native		3

#### Типы поиска в ЕЅ

Elasticsearch позволяет осуществлять поиск в режиме, близком к реальному времени с гибкостью, которую он предоставляет с типом индексируемых и просматриваемых данных.

Структурированный поиск: этот тип поиска выполняется по данным, имеющим предопределенный формат, например даты, время и числа. С предопределенным форматом появляется гибкость выполнения общих операций, таких как сравнение значений в диапазоне дат. Однако, текстовые данные тоже могут быть структурированы. Это возможно, если поле имеет фиксированное количество значений. Например, имя БД может быть:

MySQL,

MongoDB,

Elasticsearch,

ит. д.

При структурированном поиске ответ на запросы, которые мы выполняем, будет «да» либо «нет».

#### Типы поиска в ЕЅ

Полнотекстовый поиск: этот тип поиска зависит от двух важных факторов: актуальности и анализа. С помощью Relevance (актуальности) определяется, насколько хорошо некоторые данные соответствуют запросу, ставя оценку для результирующих документов. Эта оценка выставляется самим ES.

Анализ относится к разбиению текста на нормализованные токены для создания инвертированного индекса.

**Многополевой поиск:** количество аналитических запросов к хранимым в ES данным постоянно растет, поэтому мы обычно не сталкиваемся с простыми запросами выросли иля выполнения запросов которые Запрос на совпадение найдет все три документа при поиске *Удар по мячу*. Поиск по близости может сказать нам, как далеко эти два слова появляются в одной строке или абзаце, из-за чего они совпадают.

**Сопоставление с приоритетом:** запросы сегодня - это гораздо больше, чем просто определение того, содержат ли некоторые текстовые данные другую строку или нет. Речь идет об установлении связи между данными, для их оценки и сопоставления с контекстом, в котором сравниваются данные, к примеру:

- Мяч попал в Петю
- Петя ударил по мячу
- Петя купил новый мяч, который попал в окно Василия

## Типы поиска в ЕЅ

**Частичное сопоставление**, как становится понятно из названия, позволяет нам запускать запросы с частичным соответствием.

Аналогичные запросы на основе SQL(частичное соответствие)

Where имя like «Пет%"

and фамилия like "%вано%"

and дата рождения like "%.10.200%"

В некоторых случаях необходимо выполнять только запросы частичного совпадения, даже если их можно рассматривать как строгие запросы.

# СПАСИБО ЗА ВНИМАНИЕ!

